

可重构人机协同装配系统

第二篇 SCI 论文最终研究方案

事件门控双匹配异质图强化学习

Event-Gated Dual-Matching Heterogeneous Graph Reinforcement Learning

- 研究主线：** 动态混流订单驱动的工序瓶颈迁移、工人与机器人在线重配置及订单调度一体化决策
- 系统边界：** 每个装配单元仅对应一种固定工序；同一工序可配置 1-3 个并行专用单元
- 重构边界：** 仅考虑空闲工人与协作机器人在装配单元之间的重新分配
- 唯一目标：** 最小化订单总加权拖期

方案版本：Second-Paper Final Research Blueprint

文献与方法边界更新至 2026 年 7 月

目录

1 论文定位、题目与创新点	1
1.1 推荐论文题目	1
1.2 与第一篇论文的独立边界	1
1.3 三个核心创新点	2
1.4 研究问题的吸引力与论文定位	2
2 摘要与关键词	2
2.1 中文摘要	2
2.2 English Abstract	3
3 问题描述与系统边界	4
3.1 系统结构	4
3.2 订单、产品类型与工艺路线	4
3.3 异质工人与机器人	5
3.4 资源重构行为	5
3.5 动态事件与决策时刻	5
3.6 基本假设	5
4 数学模型	6
4.1 集合、索引与参数	6
4.2 决策变量	7
4.3 目标函数	7
4.4 工序唯一执行与固定单元类型约束	7
4.5 处理时间、释放时间与工艺优先约束	8
4.6 单元与资源唯一占用约束	8
4.7 配置容量与执行一致性约束	8
4.8 迁移状态转移与不可用约束	9
4.9 问题复杂性	9
5 离散事件仿真环境与决策过程	9
5.1 离散事件仿真环境	9
5.2 半马尔可夫决策过程	10
5.3 复合动作空间	10
5.4 目标一致的奖励函数	11

6 求解方法: EGDM-HGPPO	11
6.1 总体架构	11
6.2 动态异质图状态表征	12
6.2.1 节点类型及特征	12
6.2.2 关系边	12
6.2.3 关系感知图注意力更新	13
6.3 学习型事件门控策略	13
6.3.1 门控状态	13
6.3.2 门控概率与可行性掩码	13
6.4 耦合资源-单元双匹配策略	13
6.4.1 候选匹配边	13
6.4.2 掩码自回归集合解码	14
6.4.3 配置保持与迁移执行	14
6.5 订单工序-空闲单元并行匹配策略	14
6.5.1 候选动作生成	14
6.5.2 集合型并行启动	14
6.6 硬约束动作掩码	14
6.7 事件类型感知评论家	15
6.8 持续时间感知 PPO	15
6.8.1 持续时间折扣	15
6.8.2 复合动作概率	15
6.9 无专家数据的分阶段训练	16
6.10 完整算法伪代码	16
6.11 在线推理复杂度	17
7 数值实验设计	17
7.1 实验研究问题	17
7.2 算例规模设计	17
7.3 算例参数生成	18
7.4 动态场景矩阵	19
7.5 对比算法	19
7.6 算法参数设置	20
7.7 训练、验证与测试协议	20
7.8 评价指标	20
7.8.1 主指标	21

7.8.2 辅助诊断指标	21
7.9 实验组设计	21
7.9.1 实验 1: 小规模最优性验证	21
7.9.2 实验 2: 多规模综合性能	21
7.9.3 实验 3: 动态瓶颈适应性	21
7.9.4 实验 4: 迁移时间与资源柔性敏感性	21
7.9.5 实验 5: 消融实验	22
7.9.6 实验 6: 未见规模与分布泛化	22
7.9.7 实验 7: 计算效率与工业在线性	22
7.10 建议结果表	22
7.11 建议展示的结果图	23
7.12 统计检验	23
8 预期结果与可形成的研究发现	24
9 论文结构建议	24
10 投稿期刊与完成标准	25
10.1 推荐目标期刊	25
10.2 达到高水平 SCI 标准的必要条件	25
11 程序实现与代码模块建议	26
12 参考文献	26
方案结论	27

1 论文定位、题目与创新点

1.1 推荐论文题目

英文题目（推荐）：
Event-Gated Dual-Matching Heterogeneous Graph Reinforcement Learning for Integrated Resource Reconfiguration and Dynamic Scheduling in Human-Robot Collaborative Assembly Systems

中文题目：
面向人机协同装配系统资源重构与动态调度的事件门控双匹配异质图强化学习

题目中的“资源重构”专指工人与协作机器人在工序专用装配单元之间的动态重新配置，不包含工具更换、模块重构、装配单元功能变化或布局调整。该表述能够避免将本文误解为装配任务重平衡，同时突出动态订单环境下“资源配置-服务能力-订单调度”的耦合关系。

1.2 与第一篇论文的独立边界

第二篇不是第一篇方法的简单删减版，而是围绕更窄、更具工程普适性的系统结构形成独立问题。两篇论文的边界见 table 1。

表 1 第一篇与第二篇论文的研究边界区分

比较维度	第一篇论文	第二篇论文
装配单元能力	配置依赖的多工序能力，功能可随工具和资源配置变化	固定工序专用单元，每个单元仅对应一种工序
重构对象	工人、机器人、工具及人机团队	仅空闲工人与机器人
动态人因	特定人机团队熟练度演化	不考虑熟练度、疲劳、信任及个体状态演化
图结构	团队记忆时序异质超图	工序负荷-资源配置耦合异质图
决策层次	双时间尺度分层策略与世界模型前瞻	单一事件驱动策略中的门控与双匹配分解
训练机制	可包含专家预训练与世界模型	纯仿真交互训练，不使用专家数据和世界模型
核心问题	能力重构、团队重组与多工序调度	固定工序结构下的资源在线重配置与动态订单调度

1.3 三个核心创新点

创新点 1：提出固定工序专用单元下的在线人机资源重构与动态调度新问题。

在不改变工序-单元对应关系的条件下，将动态混流订单、并行工序专用单元、异质工人与协作机器人、非零资源迁移时间及订单调度统一建模。该问题区别于传统装配线平衡和一次性重平衡，其核心是随订单结构变化反复调整各工序的服务能力。

创新点 2：构建资源配置-工序负荷耦合的动态异质图表征。

通过订单工序、工序阶段、装配单元、工人和机器人五类节点，以及工艺优先、阶段归属、单元兼容、技能适配、能力适配和实时配置等多类型边，统一表达交期压力、动态瓶颈、资源位置和人机协同模式，使策略可跨订单数量、单元数量和资源规模泛化。

创新点 3：提出事件门控双匹配异质图 PPO 方法。

以学习型事件门控自适应判断是否值得重构；以耦合的“资源-单元匹配”生成工人与机器人的完整重新配置方案；以“订单工序-空闲单元匹配”并行启动多个任务；并通过持续时间感知 PPO 处理离散事件间隔不等及复合动作信用分配。

1.4 研究问题的吸引力与论文定位

现有人机协同装配研究已广泛覆盖任务分配、装配线平衡、人员结构变化后的重平衡，以及固定配置下的动态任务调度。近期研究已采用 GNN 与 PPO 处理人机协同装配动态调度，因此仅使用“GNN+PPO”无法形成充分的方法增量 [12, 11]。本文的差异化定位是：

1. 固定工艺功能而动态调整服务资源，避免与任务重平衡问题重合；
2. 将“是否重构”设为策略学习变量，而非固定周期或人工阈值；
3. 将指数级联合配置动作分解为两个受约束图匹配过程；
4. 使资源配置决策和订单调度共享同一动态异质图并联合训练；
5. 通过非零迁移时间形成“当前停机损失-未来瓶颈缓解收益”的动态权衡。

2 摘要与关键词

2.1 中文摘要

面向多品种、小批量与动态订单环境，人机协同装配系统需要根据产品组合和交期压力持续调整不同工序的服务能力。本文研究固定工序专用装配单元下的异质人机资源在线重构与动态调度问题。系统由多个工序阶段构成，每个装配单元仅能执行一种固定工序，但同一工序可配置多个并行单元；工人与协作机器人可在任务完成后跨单元迁移，其组合状态决定单元采用人工、机器人或人机协同执行模式。订单动态到达并按照既定工艺顺序流经系统，订单组合变化导致工序瓶颈随时间迁移，而资源移动会造成非零不可用时间。因此，系统需要联合决定是否触发重构、空闲工人与机器人的目标单元，以及多个空闲单元应启动的订单工序，以最小化订单总加权拖期。针对状态关系复杂、联合配置空间指数增长、多个空闲单元需同步决策以及事件间隔不等的问题，本文提出事件门控双匹配异质图 PPO

方法。首先，构建包含订单工序、工序阶段、装配单元、工人和机器人节点的动态异质图，利用关系感知图注意力提取工序负荷、交期压力 and 资源适配关系。其次，设计学习型重构门控，自适应选择保持当前配置或启动资源重构；当重构被触发时，采用耦合资源-单元指针匹配器生成工人与机器人的可行配置集合。再次，构建订单工序-空闲单元匹配器并行启动任务，避免逐单元决策顺序偏差。最后，基于持续时间折扣、目标一致的拖期积分奖励和分阶段课程学习训练联合策略。数值实验将从小规模最优性、多规模性能、动态瓶颈适应性、迁移时间敏感性、消融及未见规模泛化等方面验证方法。预期研究将为固定工艺结构下人机资源的实时重配置提供一种可扩展的端到端决策机制。

关键词： 人机协同装配；资源重构；动态调度；异质图神经网络；深度强化学习；总加权拖期

2.2 English Abstract

Human-robot collaborative assembly systems operating in high-mix, low-volume and dynamic-order environments must continuously adapt the service capacity of different assembly stages to changing product mixes and due-date pressures. This study investigates an integrated online human-robot resource reconfiguration and dynamic scheduling problem with operation-dedicated assembly cells. Each cell is dedicated to one fixed assembly stage, while multiple parallel cells may be installed for the same stage. Heterogeneous workers and collaborative robots can be reassigned across compatible cells after completing their current tasks. The resulting cell configuration automatically determines whether an operation is executed in human-only, robot-only, or collaborative mode. Dynamically arriving orders follow predefined technological routes, causing time-varying bottlenecks, whereas resource relocation incurs nonzero unavailability. The decision maker must jointly determine whether to trigger reconfiguration, where to relocate idle workers and robots, and which order operations should be launched on simultaneously idle cells, with the objective of minimizing total weighted tardiness. To address the relational state structure, exponential configuration space, concurrent dispatching decisions, and unequal event durations, an event-gated dual-matching heterogeneous graph proximal policy optimization method is proposed. A relation-aware heterogeneous graph encoder captures due-date pressure, stage workload, resource eligibility, and real-time configuration. A learned event gate decides whether the current configuration should be maintained or reconfigured. Once reconfiguration is activated, coupled resource-to-cell pointer matchers construct feasible worker and robot assignment sets. An operation-to-cell matcher then launches multiple operations in parallel without sequential-decision bias. The joint policy is trained purely through simulation interaction using duration-aware PPO, an objective-consistent tardiness-integral reward, action masking, and curriculum learning, without expert demonstrations or a learned world model. Numerical experiments are designed to evaluate optimality on small instances, scalability, adaptation to shifting bottlenecks, sensitivity to relocation times, ablation effects, and generalization to unseen system sizes.

Keywords: human-robot collaborative assembly; resource reconfiguration; dynamic scheduling; heterogeneous graph neural network; deep reinforcement learning; total weighted

tardiness

3 问题描述与系统边界

3.1 系统结构

考虑由有序工序阶段集合 $\mathcal{S} = \{1, \dots, S\}$ 构成的动态混流人机协同装配系统。每个阶段 s 配置一个或多个并行专用装配单元，记为 $\mathcal{M}_s$ ，且


$$1 \leq |\mathcal{M}_s| \leq 3, \quad \mathcal{M} = \bigcup_{s \in \mathcal{S}} \mathcal{M}_s.$$

每个单元 m 仅执行固定工序 $\kappa(m)$ ，即

$$m \in \mathcal{M}_s \implies \kappa(m) = s.$$

单元功能在整个研究周期内不改变。系统配置若干异质工人 $\mathcal{H}$ 和协作机器人 $\mathcal{R}$ 。每个单元最多容纳一名工人和一台机器人，其当前配置自动决定执行模式：

$$q_m(t) = \begin{cases} \text{H}, & \text{仅配置工人,} \\ \text{R}, & \text{仅配置机器人,} \\ \text{HR}, & \text{同时配置工人与机器人,} \\ \text{Idle}, & \text{未配置可执行资源.} \end{cases}$$



订单动态到达使各工序负荷变化；空闲工人与机器人可跨单元迁移并改变阶段服务能力

图 1 固定工序专用并行单元下的人机资源在线重配置系统示意

3.2 订单、产品类型与工艺路线

订单集合记为 $\mathcal{J}$ 。订单 j 在释放时刻 r_j 到达，具有交期 d_j 和权重 w_j 。每个订单属于产品类型 $v(j) \in \mathcal{V}$ 。不同产品共享基本工序顺序，但可跳过部分工序。定义

$$\delta_{js} = \begin{cases} 1, & \text{订单 } j \text{ 需要工序 } s, \\ 0, & \text{否则.} \end{cases}$$

订单的必需工序按照阶段索引依次执行。产品类型差异体现在工艺路线、处理时间和可执行模式上。动态到达与产品组合变化会使某些阶段短时积压，从而形成随时间迁移的瓶颈。

3.3 异质工人与机器人

定义工人技能兼容参数 $a_{hs}^H \in \{0, 1\}$ 、机器人能力兼容参数 $a_{rs}^R \in \{0, 1\}$ 以及人机协同兼容参数 $a_{hrs}^{HR} \in \{0, 1\}$ 。处理时间分别为

$$p_{jsh}^H, \quad p_{jsr}^R, \quad p_{jshr}^{HR}.$$

这些参数反映静态能力差异，但在生产周期内保持不变。本文不考虑团队熟练度、人员疲劳、机器人学习、信任或认知状态变化。

3.4 资源重构行为

资源重构仅包含：

- 空闲工人从当前装配单元迁移至另一个技能兼容单元；
- 空闲机器人从当前装配单元迁移至另一个能力兼容单元；
- 资源留在当前单元或进入暂时未配置状态。

工人和机器人仅能在完成当前任务后迁移，迁移持续时间分别为 $\tau_{hmm'}^H > 0$ 和 $\tau_{rmm'}^R > 0$ 。迁移期间资源不可执行任务。一次重构事件允许对全部空闲资源重新匹配，但忙碌资源配置保持不变。

3.5 动态事件与决策时刻

离散事件仿真仅考虑三类外生或内生事件：

1. 新订单到达；
2. 装配工序完成并释放单元及资源；
3. 工人或机器人迁移完成。

在每个事件时刻，智能体先判断是否进行资源重构；随后，对完成配置且当前空闲的单元分配待加工订单工序。当没有可执行决策时，仿真时钟直接推进至下一事件。

3.6 基本假设

1. 每个单元仅对应一种固定工序，同一工序可具有多个并行单元；
2. 每个单元最多同时配置一名工人和一台机器人；
3. 资源配置自动决定人工、机器人或人机协同执行模式；
4. 工序不可抢占，任务开始后资源和单元持续占用至完成；
5. 人机协同模式要求工人与机器人同步开始并共同占用；

6. 订单释放时间、交期、工艺路线和处理时间在订单到达时已知；
7. 不考虑设备故障、人员缺勤、质量返工、工具更换和物料搬运；
8. 安全问题通过预先定义的兼容矩阵处理，不进入在线决策模型。

4 数学模型

4.1 集合、索引与参数

表 2 主要集合与索引

符号	含义
$\mathcal{J}, j$	动态订单集合及订单索引
$\mathcal{V}, v$	产品类型集合及类型索引
$\mathcal{S}, s$	固定装配工序阶段集合及阶段索引
$\mathcal{M}_s, m$	工序 s 的并行专用单元集合及单元索引
$\mathcal{M}$	全部装配单元集合
$\mathcal{H}, h$	异质工人集合及工人索引
$\mathcal{R}, r$	异质协作机器人集合及机器人索引
$\mathcal{E}, e$	离散事件决策时刻集合及事件索引
$\mathcal{O}$	所有必需订单工序对 (j, s) 的集合

表 3 主要参数

符号	含义
r_j, d_j, w_j	订单 j 的释放时间、交期和拖期权重
δ_{js}	订单 j 是否需要工序 s
$\kappa(m)$	单元 m 对应的固定工序类型
a_{hs}^H	工人 h 对工序 s 的技能兼容性
a_{rs}^R	机器人 r 对工序 s 的能力兼容性
a_{hrs}^{HR}	工人-机器人组合 (h, r) 对工序 s 的协同兼容性
p_{jsh}^H	工人 h 单独执行订单工序 (j, s) 的时间
p_{jsr}^R	机器人 r 单独执行订单工序 (j, s) 的时间
p_{jshr}^{HR}	工人 h 与机器人 r 协同执行订单工序 (j, s) 的时间
$\tau_{hmm'}^H$	工人 h 从单元 m 移动到 m' 的迁移时间

符号	含义
$\tau_{rmm'}^R$	机器人 r 从单元 m 移动到 m' 的迁移时间
M	足够大的常数, 仅用于等价 MILP 实现

4.2 决策变量

对每个必需订单工序 $(j, s) \in \mathcal{O}$, 定义:

$$x_{jshm}^H = 1$$

表示其在单元 $m \in \mathcal{M}_s$ 上由工人 h 独立执行; x_{jsrm}^R 和 x_{jshrm}^{HR} 分别表示机器人独立及人机协同执行。定义开始时间 S_{js} 、完成时间 C_{js} 、订单完成时间 C_j 和拖期 T_j 。

在事件时刻 e 后, 定义配置变量

$$y_{hme}^H, y_{rme}^R \in \{0, 1\},$$

分别表示工人 h 、机器人 r 是否配置于单元 m 。定义迁移变量 $u_{hmm'e}^H$ 和 $u_{rmm'e}^R$ 表示资源在事件 e 后是否从 m 迁移至 m' 。

4.3 目标函数

唯一优化目标为最小化订单总加权拖期:

$$T_j \geq C_j - d_j, \quad \forall j \in \mathcal{J}, \quad (1)$$

$$T_j \geq 0, \quad \forall j \in \mathcal{J}, \quad (2)$$

$$\min \text{TWT} = \sum_{j \in \mathcal{J}} w_j T_j. \quad (3)$$

重构代价不作为独立目标。非零迁移时间使资源在迁移期间无法生产, 因此会通过 C_j 和 T_j 自然反映在目标中。

4.4 工序唯一执行与固定单元类型约束

每个必需工序恰好选择一个单元、一种模式及相应资源:

$$\sum_{m \in \mathcal{M}_s} \left(\sum_{h \in \mathcal{H}} x_{jshm}^H + \sum_{r \in \mathcal{R}} x_{jsrm}^R + \sum_{h \in \mathcal{H}} \sum_{r \in \mathcal{R}} x_{jshrm}^{HR} \right) = \delta_{js}, \quad \forall j, s. \quad (4)$$

工序只能分配给对应阶段的单元，且必须满足资源兼容性：

$$x_{jsh m}^H \leq a_{hs}^H, \quad (5)$$

$$x_{jsr m}^R \leq a_{rs}^R, \quad (6)$$

$$x_{jshr m}^{HR} \leq a_{hrs}^{HR}, \quad m \in \mathcal{M}_s. \quad (7)$$

4.5 处理时间、释放时间与工艺优先约束

处理持续时间由所选模式和资源确定：

$$\begin{aligned} C_{js} - S_{js} = & \sum_{m \in \mathcal{M}_s} \sum_h p_{jsh}^H x_{jsh m}^H + \sum_{m \in \mathcal{M}_s} \sum_r p_{jsr}^R x_{jsr m}^R \\ & + \sum_{m \in \mathcal{M}_s} \sum_h \sum_r p_{jshr}^{HR} x_{jshr m}^{HR}. \end{aligned} \quad (8)$$

订单只能在到达后加工：

$$S_{js} \geq r_j, \quad \forall (j, s) \in \mathcal{O}.$$

若 $s^-(j, s)$ 是订单 j 中工序 s 的最近前置工序，则

$$S_{js} \geq C_{j, s^-(j, s)}.$$

订单完成时间为最后一道必需工序的完成时间。

4.6 单元与资源唯一占用约束

记订单工序 (j, s) 的加工区间为 $I_{js} = [S_{js}, C_{js}]$ 。若两个工序使用相同单元，则其区间不得重叠：

$$I_{js} \cap I_{j's'} = \emptyset,$$

只要两者的分配变量指向同一单元。类似地，使用同一工人或同一机器人的任意两个工序，其加工区间不得重叠。该区间约束可通过成对排序二进制变量和 Big- M 线性化实现。

人机协同工序同时占用工人、机器人和单元，且三者开始与结束时间一致。

4.7 配置容量与执行一致性约束

每个单元最多配置一名工人和一台机器人：

$$\sum_h y_{hme}^H \leq 1, \quad \forall m, e, \quad (9)$$

$$\sum_r y_{rme}^R \leq 1, \quad \forall m, e. \quad (10)$$

每个资源同一时刻最多位于一个单元或处于迁移状态：

$$\sum_m y_{hme}^H \leq 1, \quad \forall h, e, \quad (11)$$

$$\sum_m y_{rme}^R \leq 1, \quad \forall r, e. \quad (12)$$

若工序在时刻 S_{js} 于单元 m 开始，则所需资源必须在该时刻已完成配置。用 $e(S_{js})$ 表示紧邻开始时刻之前的事件索引，有

$$x_{jsh m}^H + \sum_r x_{jsh r m}^{HR} \leq y_{hm, e(S_{js})}^H, \quad (13)$$

$$x_{jsr m}^R + \sum_h x_{jsr m}^{HR} \leq y_{rm, e(S_{js})}^R. \quad (14)$$

4.8 迁移状态转移与不可用约束

资源只能在空闲时触发迁移。若工人 h 在事件 e 从 m 移动到 m' ，则

$$u_{hmm'e}^H = 1 \implies \begin{cases} y_{hme}^H = 1, \\ y_{hm', e+1}^H = 1, \\ A_{h, e+1} \geq t_e + \tau_{hmm'}^H, \end{cases}$$

其中 $A_{h, e+1}$ 表示工人下一次可用时刻。机器人迁移约束同理。迁移区间内资源不得被任何加工工序使用。未迁移且未被重新分配的资源保持原配置。

4.9 问题复杂性

当禁止资源迁移、仅保留机器人独立模式、每个阶段拥有多个异质并行单元且订单具有释放时间和交期时，本文问题已包含带释放时间的异质并行机总加权拖期调度作为特例，该问题为 NP-hard。因此，完整的动态人机资源重构与调度问题同样属于强组合复杂问题，适合采用离线训练、在线快速推理的深度强化学习方法。

5 离散事件仿真环境与决策过程

5.1 离散事件仿真环境

仿真环境以优先队列维护未来事件，状态更新流程如下：

1. 读取最早事件时间并将仿真时钟推进至 t_{e+1} ；
2. 批量处理该时刻发生的订单到达、工序完成和资源迁移完成事件；
3. 更新订单就绪工序、各阶段队列、单元占用及资源位置；
4. 构建当前动态异质图；

5. 执行重构门控和资源-单元匹配；
6. 对配置完成且空闲的单元执行订单工序-单元匹配；
7. 生成新的加工完成与迁移完成事件；
8. 若当前无可行动作，则继续推进到下一事件。




图 2 事件驱动仿真与联合决策流程

5.2 半马尔可夫决策过程

由于相邻事件间隔 $\Delta t_e = t_{e+1} - t_e$ 不固定，将环境建模为半马尔可夫决策过程

$$\langle S, \mathcal{A}, P, R, \Gamma \rangle.$$

状态由动态图 $\mathcal{G}_e$ 表示；复合动作由门控动作、资源重构匹配集和订单调度匹配集构成；转移由离散事件仿真器精确执行。

5.3 复合动作空间

在事件 e ，动作写为

$$a_e = (g_e, A_e^{\text{rec,H}}, A_e^{\text{rec,R}}, A_e^{\text{sch}}).$$

其中 $g_e \in \{0, 1\}$ 。若 $g_e = 0$ ，两个重构匹配集为空；若 $g_e = 1$ ，

$$A_e^{\text{rec,H}} \subseteq \mathcal{H}_e^{\text{idle}} \times (\mathcal{M} \cup \{\text{stay}\}),$$

机器人匹配集类似。调度匹配集

$$A_e^{\text{sch}} \subseteq \mathcal{O}_e^{\text{ready}} \times \mathcal{M}_e^{\text{idle}}$$

要求每个工序和单元在集合中最多出现一次。

5.4 目标一致的奖励函数

令事件区间 $[t_e, t_{e+1})$ 内尚未完成且已超过交期的订单集合为

$$\mathcal{J}_e^{\text{late}} = \{j \mid t_e \geq d_j, C_j > t_e\}.$$

基础奖励定义为

$$r_e^{\text{TWT}} = -\Delta t_e \sum_{j \in \mathcal{J}_e^{\text{late}}} w_j. \quad (15)$$

整个周期的累计未折扣奖励满足

$$\sum_e r_e^{\text{TWT}} = -\sum_j w_j T_j,$$

与目标函数 eq. (3) 严格一致。迁移期间仿真时间正常推进，因此不合理迁移会自然导致拖期损失。

为改善交期前的学习信号，可选用策略不变的势函数塑形：

$$\Phi(s_e) = -\eta \sum_j w_j \max\{0, t_e + R_j^{\min}(e) - d_j\}, \quad (16)$$

$$\hat{r}_e = r_e^{\text{TWT}} + \Gamma_e \Phi(s_{e+1}) - \Phi(s_e), \quad (17)$$

其中 $R_j^{\min}(e)$ 为订单剩余必需工序的最短处理时间之和。该项不涉及流体模型，并应在消融实验中验证其必要性。

6 求解方法：EGDM-HGPPO

6.1 总体架构

提出事件门控双匹配异质图 PPO (Event-Gated Dual-Matching Heterogeneous Graph PPO, EGDM-HGPPO)。算法由共享的关系感知异质图编码器、重构门控头、工人-单元匹配头、机器人-单元匹配头、订单工序-单元匹配头和事件类型感知评论家构成。




图 3 EGDM-HGPPO 总体网络架构

6.2 动态异质图状态表征

6.2.1 节点类型及特征

构建动态图

$$\mathcal{G}_e = (\mathcal{V}_e, \mathcal{E}_e, \phi_V, \phi_E),$$

包含五类节点。

表 4 动态异质图节点及建议特征

节点类型	建议输入特征
订单工序节点	产品类型嵌入、阶段索引、就绪状态、剩余前置数、订单权重、归一化松弛时间、等待时间、各模式最短处理时间、是否已拖期
工序阶段节点	队列长度、剩余工作量、加权交期压力、并行单元数、可用/忙碌/无资源单元数、当前人力与机器人供给、负荷-能力比
装配单元节点	固定阶段类型、忙闲状态、剩余加工时间、当前队列负荷、配置工人/机器人标识、当前执行模式、下次可用时间
工人节点	技能向量、当前位置、忙闲/迁移状态、剩余忙碌时间、到各阶段迁移时间、可执行阶段比例
机器人节点	能力向量、当前位置、忙闲/迁移状态、剩余忙碌时间、到各阶段迁移时间、可执行阶段比例

连续特征使用训练分布统计量归一化；类别特征通过可学习嵌入表示。工序阶段节点作为“瓶颈枢纽”，聚合同一阶段的订单、单元和资源信息，可显著缩短远距离信息传播路径。

6.2.2 关系边

主要关系包括：工序优先边、订单工序-阶段归属边、阶段-单元所属边、工序-单元可加工边、工人-阶段技能边、机器人-阶段能力边、工人/机器人-单元当前配置边，以及同阶段订单竞争边。边特征包含迁移时间、兼容标识、等待时长和相对交期压力。

6.2.3 关系感知图注意力更新

对目标节点 v ，来自关系类型 ρ 的邻居消息为

$$\alpha_{uv}^{(l,\rho)} = \text{softmax}_{u \in \mathcal{N}_\rho(v)} \left(\frac{(W_{Q,\rho} h_v^{(l)})^\top (W_{K,\rho} h_u^{(l)} + W_{E,\rho} e_{uv})}{\sqrt{d}} \right), \quad (18)$$

$$m_{v,\rho}^{(l)} = \sum_{u \in \mathcal{N}_\rho(v)} \alpha_{uv}^{(l,\rho)} W_{V,\rho} h_u^{(l)}, \quad (19)$$

$$h_v^{(l+1)} = \text{LN} \left(h_v^{(l)} + \sigma \left(\sum_{\rho} W_{O,\rho} m_{v,\rho}^{(l)} \right) \right). \quad (20)$$

采用类型感知注意力池化获得全局图嵌入 h_G ，并分别提取阶段、单元及资源集合嵌入供各策略头使用。

6.3 学习型事件门控策略

6.3.1 门控状态

门控输入由全局图嵌入和显式动态失衡特征组成：

$$z_e^{\text{gate}} = [h_G, \text{CV}(L_s), \max_s L_s/C_s, N_e^{\text{idle}}, \Delta t_e^{\text{dwell}}, P_e^{\text{due}}],$$

其中 L_s 为阶段剩余负荷， C_s 为当前服务能力， P_e^{due} 为系统加权交期压力。

6.3.2 门控概率与可行性掩码

$$\pi_\theta^{\text{gate}}(g_e = 1 \mid \mathcal{G}_e) = \sigma(\text{MLP}_{\text{gate}}(z_e^{\text{gate}})).$$

若没有空闲可迁移资源、所有兼容单元均已满员，或距上次重构未达到最小驻留时间，则将 $g_e = 1$ 掩码为不可行。门控策略使重构时刻由状态驱动，而非依赖固定周期或人工设定的单一队列阈值。

6.4 耦合资源-单元双匹配策略

6.4.1 候选匹配边

对空闲工人 h 与目标单元 m ，仅当 $a_{h,\kappa(m)}^H = 1$ 且单元人力容量可用时建立候选边。工人匹配得分为

$$\ell_{hm}^H = f_H(h_h, h_m, h_{\kappa(m)}, h_G, \tau_{h,m(h),m}^H).$$

机器人匹配得分类似。每个资源均额外连接“保持当前位置/不配置”虚拟节点。

6.4.2 掩码自回归集合解码

为获得可计算的复合动作概率，采用带停止标记的自回归边选择：

$$\pi^{\text{rec,H}}(A^{\text{rec,H}} | \mathcal{G}_e) = \prod_{k=1}^{K_H} \pi(a_{e,k}^H | \mathcal{G}_e, a_{e,1:k-1}^H).$$

每选中一条资源-单元边后，立即掩码已分配资源和已占用容量，直至选择 STOP。机器人匹配在更新后的单元表示上执行，使其能够感知已配置工人并学习形成有价值的人机协同单元：

$$\tilde{h}_m = h_m + W_H h_{h(m)}.$$

该“工人匹配-单元状态更新-机器人匹配”耦合结构既保持精确可行性，又避免直接枚举 $(M+1)^{H+R}$ 个联合配置。

6.4.3 配置保持与迁移执行

若资源选择当前单元，则不产生迁移时间；选择新单元时，环境写入迁移完成事件并立即将资源标记为不可用。忙碌资源不进入匹配候选集合，确保重构不中断正在执行的工序。

6.5 订单工序-空闲单元并行匹配策略

6.5.1 候选动作生成

对当前就绪工序 (j, s) 与空闲单元 $m \in \mathcal{M}_s$ ，仅当单元已配置可执行资源时建立候选匹配边。当前配置对应的实际处理时间记为 $\tilde{p}_{j sm}$ 。动作得分为

$$\ell_{j sm}^{\text{sch}} = f_{\text{sch}}(h_{js}, h_m, h_s, h_G, \tilde{p}_{j sm}, \text{slack}_j).$$

6.5.2 集合型并行启动

采用第二个带 STOP 的匹配解码器逐边构造 A_e^{sch} 。选中一条订单工序-单元边后，同时掩码该工序、单元及其配置资源。由于一个事件可输出多条匹配边，多个空闲单元能够在同一仿真时刻并行开工，避免固定遍历顺序造成的策略偏差。

6.6 硬约束动作掩码

所有结构约束由环境和掩码保证，不通过奖励软惩罚。重构与调度掩码至少检查：

1. 资源是否空闲且未在迁移；
2. 资源与目标工序阶段是否兼容；
3. 单元人力和机器人容量是否可用；
4. 订单是否已到达、前置工序是否完成；

5. 单元工序类型是否与订单当前工序一致；
6. 单元当前配置是否能形成合法执行模式；
7. 同一资源、单元和订单工序是否已被本次集合动作占用；
8. 重构后是否至少保留系统基本可执行覆盖。

6.7 事件类型感知评论家

共享编码器后设置三个价值头：

$$V_{\phi}^{\text{gate}}(\mathcal{G}_e), \quad V_{\phi}^{\text{rec}}(\mathcal{G}_e), \quad V_{\phi}^{\text{sch}}(\mathcal{G}_e).$$

门控优势用于判断重构时机，重构价值头评估资源配置动作，调度价值头评估订单匹配动作。不同头共享底层结构信息，但减少不同动作频率和回报尺度造成的价值估计干扰。

6.8 持续时间感知 PPO

6.8.1 持续时间折扣

设参考时间单位为 τ_0 ，基础折扣因子为 γ ，则事件 e 的有效折扣为

$$\Gamma_e = \gamma^{\Delta t_e / \tau_0}.$$

持续时间感知 TD 残差为

$$\delta_e = \hat{r}_e + \Gamma_e V_{\phi}(s_{e+1}) - V_{\phi}(s_e).$$

广义优势估计为

$$\hat{A}_e = \sum_{l=0}^{L-1} \left(\prod_{k=0}^{l-1} \Gamma_{e+k} \lambda \right) \delta_{e+l}.$$

该机制避免将持续 1 分钟和持续 20 分钟的状态转移视为等价一步。

6.8.2 复合动作概率

事件动作的对数概率为有效子策略对数概率之和：

$$\log \pi_{\theta}(a_e | s_e) = \log \pi^{\text{gate}}(g_e) + \mathbb{I}[g_e = 1] (\log \pi^{\text{rec,H}} + \log \pi^{\text{rec,R}}) + \log \pi^{\text{sch}}.$$

PPO 剪切目标为

$$L^{\text{clip}}(\theta) = \mathbb{E}_e \left[\min \left(\rho_e \hat{A}_e, \text{clip}(\rho_e, 1 - \epsilon, 1 + \epsilon) \hat{A}_e \right) \right].$$

总损失包括策略损失、分头价值损失和各动作头熵正则：

$$L = -L^{\text{clip}} + c_V L_V - c_{E,g} H_g - c_{E,r} H_r - c_{E,s} H_s.$$

6.9 无专家数据的分阶段训练

训练完全依赖程序生成算例与离散事件仿真，不使用 MILP 专家轨迹、行为克隆或世界模型。

1. **阶段 I：固定配置调度预热。**冻结重构门控和资源匹配头，仅训练图编码器、调度匹配头及调度评论家，使策略先学会交期驱动的订单派工。
2. **阶段 II：单资源重构课程。**在小规模、低到中等负荷实例中启用门控，每次最多迁移一个工人和一个机器人，学习迁移收益与时间损失的基础权衡。
3. **阶段 III：完整集合重构。**允许全部空闲资源参与匹配，引入动态产品组合和突发到达场景，联合训练门控、双匹配和调度策略。
4. **阶段 IV：多规模联合微调。**从不同订单数、工序数和资源规模中在线采样算例，采用参数共享和特征归一化提升泛化能力。

训练稳定化措施包括并行环境采样、优势标准化、价值目标裁剪、梯度裁剪、分头熵系数退火、随机化资源解码顺序以及验证集早停。

6.10 完整算法伪代码

Input: 实例分布 Ω ; 图编码器 E_θ ; 门控策略 π_g ; 资源匹配策略 π_H, π_R ; 调度匹配策略 π_S ; 价值网络 V_ϕ

初始化网络参数、并行仿真环境和课程阶段 y **for** 每次 PPO 迭代 **do**

for 每个并行环境 **do**

从当前课程分布采样动态装配实例，初始化订单、单元和资源配置 y **while** 存在未完成订单 **do**

推进到下一事件时刻并批量更新到达、完工和迁移事件 y 构建动态异质图 $\mathcal{G}_e$ ，计算节点和全局嵌入 y 构建重构门控可行掩码并采样

$g_e \sim \pi_g(\cdot | \mathcal{G}_e)$ y **if** $g_e = 1$ **then**

以掩码指针解码工人-单元匹配集 $A_e^{\text{rec},H}$ y 更新单元配置嵌入，解码机器人-单元匹配集 $A_e^{\text{rec},R}$ y 执行资源迁移并写入迁移完成事件 y

end

构建就绪工序-空闲单元候选边及可行掩码 y 解码订单工序-单元匹配集 A_e^{sch} 并并行启动任务 y 计算事件持续时间、拖期积分奖励和可选势函数塑形奖励 y 存储复合动作对数概率、分头价值、 Δt_e 和转移 y

end

end

使用 $\Gamma_e = \gamma^{\Delta t_e / \tau_0}$ 计算持续时间感知 GAE y 对图编码器、三个策略模块和分头评论家执行多轮 PPO 更新 y 根据验证集性能调整课程阶段、熵系数和学习率 y

end

Output: 训练后的事件门控资源重构与动态调度策略

Algorithm 1: EGDM-HGPPO 训练与决策流程

6.11 在线推理复杂度

设动态图边数为 $|\mathcal{E}_e|$ ，图层数为 L ，嵌入维度为 d ，空闲工人和机器人数量分别为 H_e, R_e ，就绪工序数为 O_e ，空闲单元数为 M_e 。一次事件推理复杂度约为

$$O(L|\mathcal{E}_e|d) + O(H_eM + R_eM) + O(O_eM_e).$$

由于仅对可行候选边打分并通过掩码逐步缩小集合，在线复杂度远低于枚举全部配置和调度组合，目标是中大型算例保持亚秒级事件决策。

7 数值实验设计

7.1 实验研究问题

数值实验应回答以下研究问题：

1. EGDM-HGPPO 能否在小规模实例上接近精确方法，并在中大型动态实例上显著降低总加权拖期？
2. 学习型事件门控是否优于固定周期和人工阈值重构？
3. 双匹配策略能否有效利用异质工人与机器人缓解随产品组合变化而迁移的工序瓶颈？
4. 持续时间感知 PPO、阶段枢纽节点和集合并行调度分别贡献多大？
5. 策略能否泛化到未见订单数量、工序数量、并行单元数量和负荷水平？
6. 资源迁移时间增加时，学习策略如何从积极重构转向配置稳定？

7.2 算例规模设计

表 5 建议算例规模分层

规模	工序数 S	总单元数 M	订单数 J	工人数 H	机器人 R	产品类型数 V
S (训练/最优性)	4	5–7	15–35	3–5	2–4	3
M (训练/测试)	6	8–12	40–80	5–8	4–7	4–5
L (训练/测试)	8	12–18	90–160	8–12	6–10	6–8
XL (未见泛化)	10	18–24	180–300	12–16	9–13	8–10

每个工序设置 1–3 个并行单元，且至少 30% 的工序具有两个以上并行单元。训练分布覆盖 S、M、L 的部分组合，XL 仅用于零样本或轻量微调泛化测试。

7.3 算例参数生成

表 6 建议算例参数与生成规则

参数	建议设置	说明
基础工序时间	$\bar{p}_{vs} \sim U[8, 25] \text{ min}$	产品类型与工序相关
工人效率	$\eta_{hs}^H \sim U[0.80, 1.20]$	$p_{jsh}^H = \bar{p}_{v(j)s} / \eta_{hs}^H$
机器人效率	$\eta_{rs}^R \sim U[0.85, 1.30]$	机器人可在部分重复性工序更快
协同增益系数	$\xi_{hrs} \sim U[0.65, 0.90]$	$p_{jshr}^{HR} = \xi_{hrs} \min(p_{jsh}^H, p_{jsr}^R)$
工人技能密度	0.60、0.75、0.90	每名工人可执行阶段比例，保证每阶段有覆盖
机器人能力密度	0.50、0.65、0.80	形成低/中/高柔性场景
协同兼容性	条件兼容组合的 70–100%	安全验证后的可行人机组合
订单到达	分段泊松过程	稳态、突发和产品组合迁移三种场景
系统负荷率	$\rho \in \{0.65, 0.80, 0.95\}$	低、中、高负荷
工艺路线	每类产品需要 70–100% 阶段	保持阶段顺序，允许跳站
订单权重	$w_j \in \{1, 2, 4\}$ ，概率 $\{0.6, 0.3, 0.1\}$	普通、重要、紧急订单
交期	$d_j = r_j + \kappa_j \sum_s p_{js}^{\min}$	κ_j 控制交期松紧
交期系数	紧 $[1.3, 1.7]$ ；中 $[1.7, 2.1]$ ；松 $[2.1, 2.6]$	三类交期环境
资源迁移时间	相邻单元 $U[1, 3]$ ；跨阶段 $U[3, 8] \text{ min}$	敏感性分析可乘 0.5–2.0 倍
初始配置	负荷均衡启发式 + 随机扰动	防止固定初始配置偏置
事件最小驻留时间	0、5、10 min	训练默认 5 min，并进行敏感性分析

协同时间生成式仅用于构造固定的静态处理时间差异，不表示人机协同熟练度或随合作次数变化的学习效应。正式工业案例应使用实际节拍数据替代随机生成参数。

7.4 动态场景矩阵

表 7 建议动态场景设置

场景	到达过程	产品组合变化	研究目的
D1 稳态	固定强度泊松到达	固定产品比例	基础性能与规模扩展
D2 到达突发	中段到达强度提升 50–100%	比例不变	验证短时积压下重构响应
D3 组合迁移	到达强度稳定	中段主导产品由 A 切换至 B	验证瓶颈阶段迁移适应性
D4 双重冲击	到达强度和产 品比例同时变化	两次结构变化	验证复杂动态下稳定性
D5 紧急订单	正常流中插入高权 重订单批次	局部改变	验证交期权重驱动决策

7.5 对比算法

表 8 建议对比算法及作用

算法	说明
CP-SAT/MILP	小规模离线精确或有限时间求解，评估最优性差距
RH-MILP	滚动时域数学规划，周期性重新优化有限窗口
RH-ALNS	滚动时域自适应大邻域搜索，作为强启发式基线
Fixed-EDD	固定初始配置，按最早交期调度
Periodic-ATC	固定周期按阶段负荷重新分配资源，使用 ATC 规则派工
Threshold-EDD	当最大阶段负荷-能力比超过阈值时重构，使用 EDD 派工
Bottleneck-Rule	将空闲资源迁移至预计负荷最高的兼容阶段
MLP-PPO	使用人工汇总状态与扁平动作的 PPO
GAT-PPO	普通同质图编码，不区分关系类型
HGT-PPO-Flat	异质图编码，但直接使用扁平单动作决策
HGT-MAPPO	工人、机器人和调度智能体分散决策，共享奖励
EGDM-HGPPO	本文完整方法

所有强化学习算法应使用同一离散事件仿真器、相同训练实例分布、相同交互步数和近似参数规模。规则与启发式算法不得使用强化学习方法不可见的未来到达信息。

7.6 算法参数设置

表 9 EGDM-HGPPO 建议算法参数

参数	推荐值	说明
图嵌入维度	128	所有节点类型投影至统一维度
异质图层数	3	兼顾传播范围与过平滑
注意力头数	4	每头维度 32
关系类型嵌入	32	用于边类型与事件类型编码
策略/价值 MLP	256–128	GELU 激活与 LayerNorm
优化器	AdamW	权重衰减 10^{-5}
初始学习率	3×10^{-4}	编码器可设为 2×10^{-4}
学习率调度	线性衰减	衰减至初值的 10%
PPO 裁剪系数	0.20	ϵ
基础折扣因子	0.995	以 $\tau_0 = 10 \text{ min}$ 为参考
GAE 参数	0.95	λ
价值损失系数	0.5	三个价值头加权求和
门控熵系数	0.01→0.001	防止早期始终保持/始终重构
匹配熵系数	0.02→0.002	资源与调度头独立退火
并行环境数	32	中型实例，可按 GPU 显存调整
每轮采样事件数	8192	所有环境合计
小批量大小	512	按事件转移随机打乱
每轮 PPO 更新	4 epochs	避免策略过度更新
梯度裁剪	0.5	全局范数
课程阶段	4	固定配置、单资源、全资源、多规模
随机种子	5	报告均值、标准差及显著性

7.7 训练、验证与测试协议

1. 训练算例在线生成，训练过程中不重复使用固定测试实例；
2. 验证集包含各训练规模和动态场景的固定实例，用于早停和超参数选择；
3. 每个测试组合生成至少 100 个独立实例，每个训练随机种子均在相同实例上评估；
4. S 规模小实例允许 CP-SAT/MILP 求解至最优或给定 1 小时上限；
5. 所有在线决策方法在相同 CPU/GPU 平台测量事件平均推理时间；
6. 主要结果报告均值、标准差、中位数、95% 置信区间和相对改进率；
7. 模型选择仅使用验证集，不根据测试结果调整参数。

7.8 评价指标

7.8.1 主指标

$$\text{TWT} = \sum_j w_j T_j.$$

这是算法排序的唯一生产目标。

7.8.2 辅助诊断指标

辅助指标不参与优化，用于解释策略行为：

- 拖期订单比例 N^{tardy}/J ;
- 平均订单流经时间;
- 重构触发次数和每次迁移资源数;
- 工人/机器人累计迁移时间;
- 各阶段负荷-能力比的变异系数;
- 人工、机器人和协同模式使用比例;
- 平均事件决策时间及 95 分位决策时间;
- 小规模最优性差距 $(\text{TWT} - \text{TWT}^*)/\text{TWT}^*$ 。

7.9 实验组设计

7.9.1 实验 1：小规模最优性验证

在 S 规模、订单数 15–30 的实例上比较 CP-SAT/MILP、RH-MILP、RH-ALNS 及各 DRL 算法。报告最优性差距、求解时间和未在时限内证明最优的实例比例。

7.9.2 实验 2：多规模综合性能

在 S、M、L 三个规模和三种负荷率下比较总加权拖期。应按规模与交期松紧分别报告，避免总体均值掩盖算法在高负荷紧交期场景中的差异。

7.9.3 实验 3：动态瓶颈适应性

在 D2–D4 场景中记录各阶段队列负荷、配置工人数、配置机器人数量和门控概率随时间变化，验证策略是否在产品组合切换后将资源迁移至新的瓶颈阶段。

7.9.4 实验 4：迁移时间与资源柔性敏感性

将迁移时间乘数设置为 $\{0, 0.5, 1.0, 1.5, 2.0\}$ ，技能/能力密度设置为低、中、高。分析重构频率、资源稳定性和总加权拖期的变化规律。

7.9.5 实验 5：消融实验

表 10 建议消融变体

变体	删除或替换内容
w/o Event Gate	每个事件均允许重构，检验门控抑制过度迁移的作用
Periodic Gate	用固定周期替换学习型门控
w/o Stage Nodes	删除阶段枢纽节点，仅依赖操作-单元局部传播
Homogeneous GAT	将关系感知异质图替换为普通 GAT
Flat Reconfiguration	用单资源逐步动作替代完整资源-单元匹配
Sequential Dispatch	按固定单元顺序逐个派工，替代集合型调度匹配
w/o Duration-aware GAE	使用常数一步折扣，检验非等间隔事件处理
w/o Potential Shaping	仅采用严格拖期积分奖励
Single Critic	三个价值头替换为单一价值网络

7.9.6 实验 6：未见规模与分布泛化

将训练于 S-L 部分规模的模型直接测试于 XL 规模、未见产品类型数量、未见并行单元分布以及更高负荷率。可进一步测试不同资源数量下的零样本迁移能力。

7.9.7 实验 7：计算效率与工业在线性

报告随订单数、单元数和资源数增长的平均/95 分位推理时间、显存占用及每秒可处理事件数。对 RH-MILP 和 RH-ALNS 报告相同硬件下的在线求解时间。

7.10 建议结果表

表 11 建议主结果表结构（不填入虚构结果）

算法	S 规模 TWT	M 规模 TWT	L 规模 TWT	相对改进	决策时间/ms
CP-SAT/MILP	—	—	N/A	—	—
RH-ALNS	—	—	—	—	—
Threshold-EDD	—	—	—	—	—
MLP-PPO	—	—	—	—	—
HGT-PPO-Flat	—	—	—	—	—
EGDM-HGPPO	—	—	—	—	—

其他建议表包括：小规模最优性差距表、动态场景稳健性表、消融实验表、未见规模泛化表、迁移敏感性表和统计检验表。

7.11 建议展示的结果图

表 12 建议结果图及展示要点

编号	图名	建议内容
F1	系统结构与动态资源重构示意	展示固定工序专用单元、并行单元、人机资源池和迁移路径
F2	动态异质图快照	用不同形状表示订单工序、阶段、单元、工人和机器人，标注关键关系边
F3	EGDM-HGPPO 网络架构	展示共享编码器、事件门控、双资源匹配、调度匹配和分头评论家
F4	训练收敛曲线	五个随机种子的滑动均值及 95% 置信带，不只展示单次最好曲线
F5	多规模性能箱线图	横轴算法，纵轴归一化 TWT，按 S/M/L 分面
F6	负荷率-交期紧度热力图	单元格显示 EGDM 相对最强基线的改进率
F7	阶段负荷与资源配置时间序列	上半图为阶段队列负荷，下半图为工人/机器人配置数量，标注重构事件
F8	产品组合切换案例甘特图	展示订单加工、资源迁移和重构前后瓶颈变化
F9	门控概率与失衡程度关系	散点/分箱曲线展示门控对负荷-能力失衡和迁移时间的响应
F10	迁移时间敏感性曲线	横轴迁移时间倍数，双纵轴为 TWT 和重构次数
F11	消融实验瀑布图或条形图	量化各结构删除后的性能退化
F12	未见规模泛化曲线	横轴订单数或图节点数，展示 TWT 差距和决策时间
F13	执行模式使用比例	堆积柱状图展示 H/R/HR 模式随负荷和资源结构变化
F14	决策时间扩展性	双对数坐标展示不同算法的事件推理时间随问题规模增长

7.12 统计检验

对每个规模与场景，使用配对 Wilcoxon 符号秩检验比较 EGDM-HGPPO 与各基线，并采用 Holm 方法校正多重比较。跨多个实例组的整体排序采用 Friedman 检验；显著时使用 Nemenyi 或 Holm 事后检验。除 p 值外，应报告效应量（如 Cliff's delta）和 95% 置信区间。强化学习训练稳定性需报告 5 个独立随机种子。

8 预期结果与可形成的研究发现

本文不预设或虚构具体改进百分比，但实验应争取形成以下可检验发现：

1. 固定配置在稳态低负荷下已具有竞争力，但在产品组合突变和高交期压力下，动态重构可显著降低阶段能力失配造成的拖期；
2. 学习型门控能够在迁移时间较大时主动减少重构，在瓶颈明显迁移时快速提高重构概率，优于固定周期和单阈值策略；
3. 人机资源双匹配可通过形成 H、R 和 HR 三类服务模式，兼顾阶段覆盖与处理效率，而非简单把全部机器人集中到当前队列最长阶段；
4. 阶段枢纽节点和关系感知注意力对跨规模泛化具有关键作用；
5. 集合型并行调度在多并行单元场景中优于固定顺序逐单元派工；
6. 资源柔性存在边际收益：当技能覆盖达到较高水平后，继续增加兼容性带来的收益逐渐降低；
7. 迁移时间与动态性之间存在临界关系，超过某一范围后，保持稳定配置比频繁追逐短期瓶颈更优。

9 论文结构建议

1. **Introduction:** 从动态产品组合、固定工序结构和人机资源可移动性切入；明确与装配线平衡、一次性重平衡和固定配置动态调度的区别；给出三个贡献。
2. **Literature Review:** 人机协同装配线平衡与重平衡；动态 HRC 任务调度；制造调度中的图强化学习；动态资源配置与匹配决策。
3. **Problem Description and Mathematical Formulation:** 系统结构、动态事件、资源迁移、唯一目标及约束。
4. **Event-Driven Decision Model:** 离散事件仿真、异质图状态、复合动作与目标一致奖励。
5. **EGDM-HGPPO:** 图编码器、事件门控、双资源匹配、订单匹配、持续时间 PPO 和训练方法。
6. **Experimental Design:** 算例、基线、公平性、参数、评价与统计方法。
7. **Results and Discussion:** 综合性能、动态瓶颈案例、消融、敏感性、泛化及管理启示。
8. **Industrial Case:** 建议加入电池包、汽车零部件或机电产品混流装配案例，至少展示真实工序、单元及资源参数标定。
9. **Conclusion:** 总结问题、方法和动态资源配置规律，并提出故障、人员状态和工具重构等后续扩展。

10 投稿期刊与完成标准

10.1 推荐目标期刊

表 13 建议投稿期刊及匹配条件

期刊	建议定位
Robotics and Computer-Integrated Manufacturing	首选；强调人机资源重配置、实时决策、工业案例与在线性
Journal of Manufacturing Systems	强调系统级动态瓶颈、异质图强化学习、泛化与制造系统机制
International Journal of Production Economics	强调新问题建模、动态资源配置规律、强基线与管理启示
International Journal of Production Research	强调严谨模型、工业场景、算法验证和敏感性分析
Computers & Industrial Engineering	稳妥选择；要求完整模型、强算法和大规模实验
Advanced Engineering Informatics	若突出动态图表示、跨规模泛化和智能决策架构

10.2 达到高水平 SCI 标准的必要条件

1. 文献综述必须清楚区分“任务重分配”“装配线重平衡”和“运行期资源重构”；
2. 小规模实例必须有精确算法或可证明下界进行最优性参照；
3. 强化学习基线不能只包含 DQN/PPO，应包含异质图 PPO 和多智能体方法；
4. 动态场景必须包含产品组合迁移，而不只是随机处理时间扰动；
5. 必须以同一仿真器、训练预算和硬件保证算法公平性；
6. 必须报告多随机种子、显著性、效应量、决策时间和未见规模泛化；
7. 工业案例至少需要真实或半真实的工序、资源兼容、节拍和迁移时间参数；
8. 结果讨论需要提炼何时应重构、资源柔性价值和迁移时间阈值等制造管理规律。

11 程序实现与代码模块建议

表 14 建议代码项目结构

模块	主要职责
<code>instances/</code>	产品路线、处理时间、技能矩阵、迁移矩阵、动态到达和交期生成
<code>env/events.py</code>	订单到达、加工完成、迁移完成事件对象与优先队列
<code>env/simulator.py</code>	离散事件推进、资源状态、动作执行、奖励与终止条件
<code>env/masks.py</code>	重构门控、资源匹配和调度匹配的硬约束掩码
<code>graph/builder.py</code>	将仿真状态转换为异质图及批量图数据
<code>models/encoder.py</code>	关系感知异质图注意力编码器
<code>models/gate.py</code>	事件重构门控策略
<code>models/matching.py</code>	工人、机器人和订单工序的掩码指针匹配器
<code>models/critic.py</code>	门控、重构和调度分头价值网络
<code>rl/ppo.py</code>	持续时间感知 GAE、PPO 更新、熵退火和梯度裁剪
<code>train/curriculum.py</code>	四阶段课程学习和多规模采样
<code>baselines/</code>	CP-SAT、RH-MILP、ALNS、规则、MLP-PPO、GAT/HGT/MAPPO
<code>experiments/</code>	批量测试、统计检验、结果表和科研绘图

实现时建议使用 PyTorch 与 PyTorch Geometric，采用向量化节点特征和批图训练。离散事件环境应与所有强化学习和规则基线共享，避免因环境推进机制不同造成比较偏差。

12 参考文献

参考文献

- [1] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms. *arXiv:1707.06347*, 2017.
- [2] Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., and Bengio, Y. Graph attention networks. *International Conference on Learning Representations*, 2018.
- [3] Hu, Z., Dong, Y., Wang, K., and Sun, Y. Heterogeneous graph transformer. *Proceedings of the Web Conference*, 2020, 2704–2710.
- [4] Yu, T., Huang, J., and Chang, Q. Optimizing task scheduling in human–robot collaboration with deep multi-agent reinforcement learning. *Journal of Manufacturing Systems*, 60, 487–499, 2021.
- [5] Zhang, R. et al. A reinforcement learning method for human–robot collaborative task allocation and scheduling in assembly processes. *Robotics and Computer-Integrated Manufacturing*, 2022.

- [6] Kheirabadi, M., Keivanpour, S., Chinniah, Y. A., and Frayret, J.-M. Human-robot collaboration in assembly line balancing problems: Review and research gaps. *Computers & Industrial Engineering*, 186, 109737, 2023.
- [7] Mao, Z., Sun, Y., Fang, K., Huang, D., and Zhang, J. Balancing and scheduling of assembly line with multi-type collaborative robots. *International Journal of Production Economics*, 271, 109207, 2024.
- [8] Karas Çelik, A., and Özçelik, F. Assembly line rebalancing problem with human-robot collaboration and a hyper-matheuristic solution approach. *Computers & Industrial Engineering*, 200, 110795, 2025.
- [9] Wang, J., Yan, Y., Hu, Y., Yang, X., and Zhang, L. A transfer reinforcement learning and digital-twin based task allocation method for human-robot collaboration assembly. *Engineering Applications of Artificial Intelligence*, 144, 110064, 2025.
- [10] Binotto, S., Dalla Libera, A., Granata, I., Minto, R., Calzavara, M., Faccio, M., and Susto, G. A. Value-based reinforcement learning for task scheduling in human-robot applications. *IFAC-PapersOnLine*, 2025. doi:10.1016/j.ifacol.2025.12.023.
- [11] Wang, D., Liu, S., Zou, J., Qiao, W., and Jin, S. Flexible robotic cell scheduling with graph neural network based deep reinforcement learning. *Journal of Manufacturing Systems*, 2025. doi:10.1016/j.jmsy.2024.11.010.
- [12] Jia, Z. et al. Dynamic scheduling of human-robot collaboration with deep reinforcement learning. *Production Engineering*, 2026. doi:10.1007/s11740-026-01448-0.
- [13] Nourmohammadi, A. et al. Balancing human-robot collaborative assembly lines. *Computers & Industrial Engineering*, 2025.
- [14] Zheng, C. et al. Balancing and scheduling human-robot collaborative assembly lines with heterogeneous collaborative robots and limited resources. *Computers & Industrial Engineering*, 2025.

方案结论

第二篇论文最终锁定为：动态混流订单环境下，固定工序专用并行装配单元中的异质工人与协作机器人在线重配置及订单调度问题，以总加权拖期为唯一目标。求解方法采用不依赖专家数据和世界模型的 EGDM-HGPPO，通过动态异质图、学习型事件门控、工人/机器人-单元双匹配、订单工序-单元并行匹配及持续时间感知 PPO，实现结构化、可扩展的端到端决策。

该方案的核心优势是问题边界清晰、程序实现可控、与第一篇论文差异充分，并能通过动态瓶颈迁移、重构时机学习和跨规模泛化形成独立的科学与方法贡献。